Học máy – Ba bài giảng

ML tổng hợp

Lý thuyết gọn, ví dụ tính từng bước

Mô hình tuyến tính, mạng nơ-ron
Transformer và phương pháp thực nghiệm

Chọn mô hình
Biểu diễn được quy luật cần học

Dữ liệu và hàm mất mát

Học tham số
Gradient, backprop và tối ưu

Dữ liệu mới

Đánh giá
Tổng quát hóa và kết quả theo nhóm

Mục lục

01 Nền tảng học máy

02 Hồi quy và gradient descent

03 Phân loại và loss

04 Công bằng và Group DRO

05 Feature phi tuyến

06 Mạng nơ-ron và forward

07 Backpropagation

08 CNN

09 Embedding, RNN và LSTM

10 Attention và Transformer

11 BERT và mô hình ngôn ngữ

12 Tổng quát hóa

13 Thực nghiệm và phân tích lỗi

14 K-means và RFM

Phím → hoặc Tiếp để hiện bước / đáp án. Nhấn P để mở ghi chú người trình bày

Học và suy diễn

Dữ liệu train
Cặp đầu vào và kết quả thật

→

Huấn luyện
Tìm tham số của mô hình

→

Suy diễn
Dự đoán cho đầu vào mới

- **Mô hình** f_θ: hàm tạo dự đoán
- **Tham số** θ: trọng số, bias được học
- **Siêu tham số**: số lớp, tốc độ học, hệ số L2

Một lần suy diễn có thể nhanh dù cả đợt huấn luyện cần nhiều bước

Loại bài toán dự đoán

Đầu ra	Bài toán	Ví dụ
Hai nhãn	Phân loại nhị phân	Gian lận, bình luận độc hại
Một trong K nhãn	Phân loại đa lớp	Chữ số 0–9
Số thực	Hồi quy	Giá nhà, thời gian đến nơi
Chuỗi hoặc đối tượng phức tạp	Dự đoán có cấu trúc	Dịch, chú thích, phân vùng ảnh

Mã lớp “7” là nhãn. “7 phút” là số đo có đơn vị

Ba quyết định thiết kế

Quyết định	Câu hỏi	Ví dụ
Lớp giả thuyết $\mathcal{F}$	Cho phép những hàm nào?	Đường thẳng hay mạng sâu
Loss ℓ	Đo dự đoán sai thế nào?	Bình phương, hinge, cross-entropy
Optimizer	Tìm tham số bằng cách nào?	Gradient descent, SGD

$$J(\theta) = \frac{1}{n}\sum_{i=1}^{n} \ell(f_\theta(x_i), y_i) + \lambda R(\theta)$$

Các ký hiệu dùng xuyên suốt

Ký hiệu	Ý nghĩa
$x_i, y_i, \hat{y}_i$	Đầu vào, giá trị thật, dự đoán
$\phi(x) \in \mathbb{R}^d$	Vector đặc trưng
w, b	Trọng số và bias
$\nabla_w J, \eta, \lambda$	Gradient, tốc độ học, hệ số điều chuẩn

$$w^\top \phi(x) = \sum_j w_j \phi_j(x)$$

Tích vô hướng cho một số. Tích ngoài cho ma trận. Ký hiệu $\odot$ là nhân từng phần tử

Tự luyện – Tên lớp bằng số có phải hồi quy?

Không. Cần xét ý nghĩa đầu ra: chọn lớp hay dự đoán đại lượng có khoảng cách và đơn vị.

Thử trả lời trước khi bấm Tiếp

Hồi quy tuyến tính và bias

$$\hat{y} = b + wx = w^\top \phi(x), \qquad \phi(x) = [1, x]^\top$$

Thành phần	Ý nghĩa
b	Giá trị dự đoán khi đầu vào bằng không
w	Mức thay đổi dự đoán khi đầu vào tăng một đơn vị
Feature hằng 1	Cho phép gộp bias vào trọng số

Bỏ bias sẽ buộc đường đi qua gốc tọa độ

Ví dụ ba điểm

x	1	2	4
y	1	3	3

Đường trong bài giảng: $f(x) = 1 + 0.57x$

01 Đầu vào mới x = 3

02 Thay vào mô hình: 1 + 0,57 × 3

Dự đoán bằng **2,71**

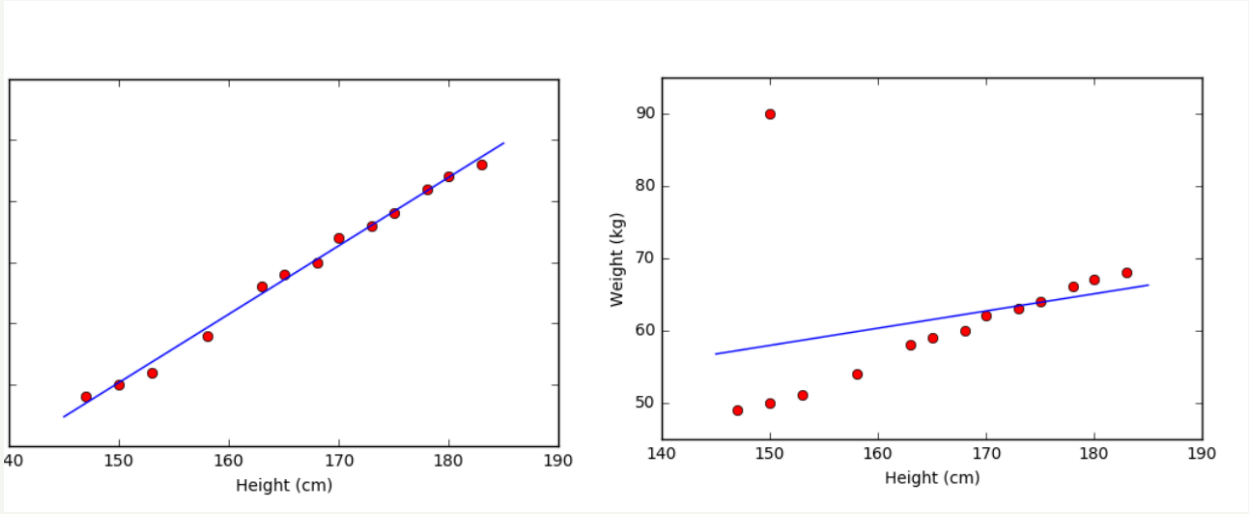
Phần dư và MSE

$$r_i = \hat{y}_i - y_i, \qquad \ell_i = r_i^2, \qquad J = \frac{1}{n}\sum_i r_i^2$$

Mẫu	Dự đoán	Phần dư	Loss
$(1, 1)$	1,57	0,57	0,3249
$(2, 3)$	2,14	−0,86	0,7396
$(4, 3)$	3,28	0,28	0,0784

MSE ≈ **0,38097**. Tổng phần dư gần không vì hai dấu có thể triệt tiêu

Bình phương sai số và ngoại lai



Chiều cao (cm) và cân nặng (kg), panel A031 trong PDF

- Bình phương loại bỏ triệt tiêu dấu, phạt mạnh sai lệch lớn
- Điểm ngoại lai có thể kéo đường lệch khỏi xu hướng đa số

Gradient của hồi quy

$$\frac{\partial \ell_i}{\partial w_j} = 2(\hat{y}_i - y_i)\phi_j(x_i)$$

$$\nabla_w J = \frac{2}{n}\sum_i (w^\top \phi(x_i) - y_i)\phi(x_i)$$

Gradient gom đạo hàm theo từng trọng số. MSE dùng trung bình nên phải chia số mẫu

Một bước gradient descent

$$w^{(t+1)} = w^{(t)} - \eta \nabla J(w^{(t)})$$

Khởi tạo $w = [0, 0]^\top$, tốc độ học $\eta = 0.1$

Mẫu	Gradient loss từng mẫu
$(1, 1)$	$[-2, -2]$
$(2, 3)$	$[-6, -12]$
$(4, 3)$	$[-6, -24]$

Gradient trung bình ≈ (−4,667, −12,667)
Trọng số mới ≈ **(0,467, 1,267)**

Tốc độ học và hội tụ

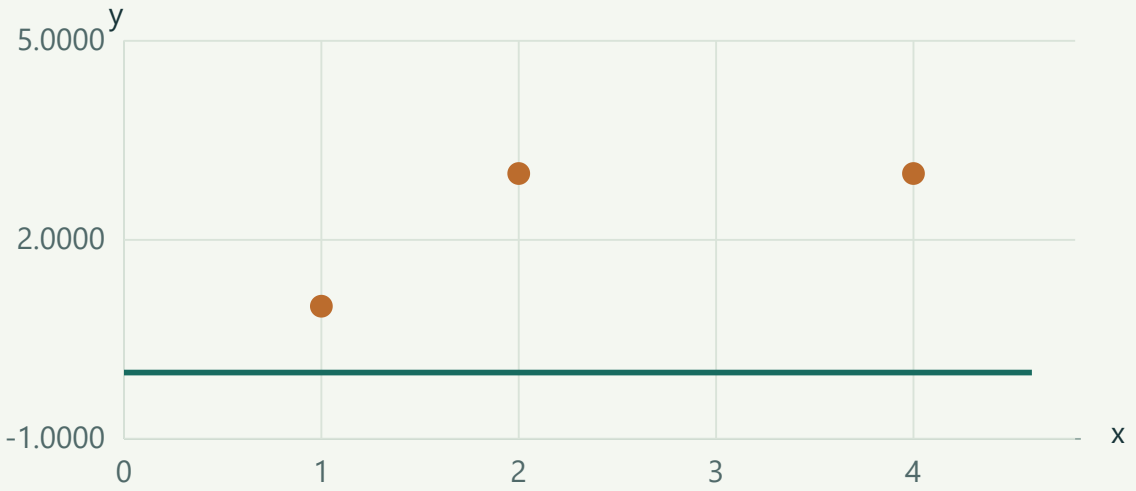
Bước học	Hành vi có thể gặp
Quá nhỏ	Loss giảm chậm
Phù hợp	Tiến dần tới nghiệm
Quá lớn	Dao động mạnh hoặc phân kỳ

$$\nabla^2 J = \frac{2}{n}\Phi^\top \Phi \succeq 0$$

Loss bình phương tuyến tính là hàm lồi khi feature cố định. Bước học vẫn phải phù hợp

Thử từng bước học

Tốc độ học 0.1 | Học 1 bước | Thêm 10 bước | Đặt lại



Bước học
0

Bias
0.0000

Độ dốc
0.0000

MSE
6.3333

Điểm nâu: dữ liệu (1,1), (2,3), (4,3). Đường xanh: mô hình hiện tại.
Nghiệm: bias = 1, độ dốc = 4/7, MSE ≈ 0,380952.

Nghiệm của ví dụ ba điểm

$$w^* = \begin{bmatrix} 1 \\ 4/7 \end{bmatrix}, \qquad f(x) = 1 + \frac{4}{7}x, \qquad J_{\min} = \frac{8}{21}$$

- Ba điểm không thẳng hàng nên MSE nhỏ nhất vẫn dương
- Dừng thực tế: gradient nhỏ, loss ít cải thiện hoặc hết số bước

Công thức gradient sẽ mất hệ số 2 nếu định nghĩa loss có thêm hệ số 1/2

Tự luyện – Gradient bằng không có nghĩa loss bằng không?

Không. Mô hình có thể đã đạt nghiệm tốt nhất trong lớp nhưng vẫn còn sai số không thể khớp.

Thử trả lời trước khi bấm Tiếp

Score, nhãn và ranh giới

$$s(x) = w^\top x + b, \qquad \hat{y} = \operatorname{sign}(s(x))$$

- Ranh giới nhị phân: $w^\top x + b = 0$
- w vuông góc với ranh giới và hướng về score tăng
- Đa lớp: chọn $\hat{y} = \arg\max_j s_j(x)$

Score có thể âm. Nó chưa phải xác suất

Khoảng cách và functional margin

$$m = y\, s(x), \qquad d_{\text{signed}} = \frac{s(x)}{\|w\|}$$

Margin	Ý nghĩa
$m < 0$	Sai dấu
$0 < m < 1$	Đúng dấu, chưa đạt biên hinge
$m \geq 1$	Hinge không còn phạt

Nhân cả w và b với số dương giữ nguyên ranh giới nhưng đổi score và functional margin

Loss 0–1 và hinge

$$\ell_{01} = \mathbf{1}[\hat{y} \neq y], \qquad \ell_{\text{hinge}} = \max(0, 1 - m)$$

Margin	Loss 0–1	Hinge
−2	1	3
0,3	0	0,7
2	0	0

0–1 khó học trực tiếp bằng gradient. Hinge còn phạt điểm đúng nhưng sát ranh giới

Gradient hinge và L2

$$\nabla_w \ell = \begin{cases} -y\phi(x), & m < 1 \\ 0, & m > 1 \end{cases}$$

$$J_{\text{reg}} = \frac{1}{n}\sum_i \ell_i + \frac{\lambda}{2}\|w\|^2, \quad \nabla J_{\text{reg}} = \nabla J + \lambda w$$

- Tại $m = 1$, dùng một subgradient hợp lệ
- L2 kiểm soát độ lớn trọng số, bias thường để ngoài phần phạt

Logistic và binary cross-entropy

$$\ell_{\text{logistic}} = \log(1 + e^{-ys}), \qquad y \in \{-1, +1\}$$

$$p = \sigma(s), \qquad \ell_{\text{BCE}} = -t \log p - (1 - t) \log(1 - p)$$

Với $t = 1$: xác suất 0,9 cho loss ≈ 0,1053

Xác suất 0,1 cho loss ≈ 2,3026

BCE dùng nhãn t ∈ {0,1}. Logistic dạng margin dùng nhãn ±1

Softmax và cross-entropy đa lớp

$$p_j = \frac{e^{s_j}}{\sum_k e^{s_k}}, \quad \ell = -\log p_y, \quad \frac{\partial \ell}{\partial s_j} = p_j - \mathbf{1}[j = y]$$

Score $[2, 1, 3]$, nhãn đúng là lớp 1

01 Softmax ≈ (0,2447, 0,0900, 0,6652)

Mô hình chọn lớp 3, cross-entropy ≈ **1,4076**

Trừ score lớn nhất trước khi lấy hàm mũ giúp tính ổn định

Hinge SVM đa lớp

$$\ell_i = \sum_{j \neq y_i} \max(0, s_j - s_{y_i} + \Delta)$$

Score $[2, 1, 3]$, nhãn đúng lớp 1, biên $\Delta = 1$

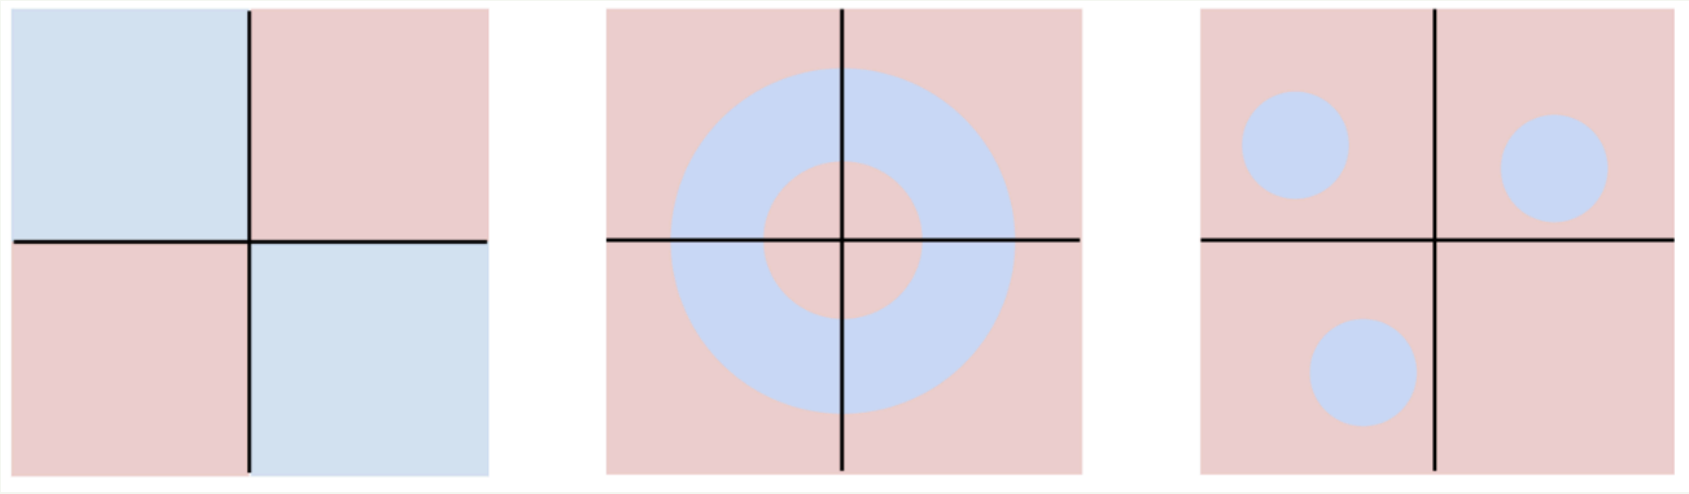
01 Lớp 2 góp max(0, 1 − 2 + 1) = 0

02 Lớp 3 góp max(0, 3 − 2 + 1) = 2

Tổng loss bằng **2**

SVM có cả nhị phân và đa lớp. Có biến thể lấy max thay vì tổng

Giới hạn của ranh giới tuyến tính



XOR, vành tròn và các vùng tách rời, panel A060

Cần đổi feature hoặc dùng biểu diễn phi tuyến khi một siêu phẳng trong đầu vào gốc không đủ

Thiết kế loss và phần mở rộng theo góc

Loss	Khi dự đoán đã tốt
Hinge	Gradient dừng khi đạt biên
Logistic	Loss tiếp tục giảm mượt
Ví dụ MERU / ARGENT trong nguồn	So sánh tín hiệu phạt ở các miền góc

$$\ell = [\mathrm{ext}(x, y) - \mathrm{aper}(x)]_+$$

Hai slide nghiên cứu chỉ đủ minh họa hành vi loss. Chưa đủ định nghĩa để tái tạo phương pháp hoặc kết luận ưu thế

Tự luyện – Đúng dấu đã hết hinge loss?

Chỉ khi margin đạt ít nhất một. Với nhãn -1 và score $-0{,}2$, margin = $0{,}2$ nên hinge = **0,8**.

Thử trả lời trước khi bấm Tiếp

Ba nguyên tắc công bằng phân phối

Giả định có **100 liều vaccine cho 1.000 người**

Nguyên tắc	Cách ưu tiên trong ví dụ
Tối đa phúc lợi	Lợi ích tổng thể, hiệu quả phục vụ
Người bất lợi nhất	Người dễ chịu hậu quả nặng, khó tiếp cận
Tránh tăng bất công	Nhóm từng bị gạt khỏi cơ hội tiếp cận

Accuracy chung không mô tả đầy đủ cách phân phối lợi ích và gánh nặng

Chênh lệch hiệu năng theo nhóm

Gender Classifier	Darker Male	Darker Female	Lighter Male	Lighter Female	Largest Gap
Microsoft	94.0%	79.2%	100%	98.3%	20.8%
FACE++	99.3%	65.5%	99.2%	94.0%	33.8%
IBM	88.0%	65.3%	99.7%	92.9%	34.4%

Bảng được dẫn trong ví dụ Gender Shades năm 2018, panel B005

- So từng nhóm trong cùng một hệ thống trước khi xem trung bình
- Xem cả loại lỗi và hậu quả của lỗi

Số liệu được dẫn theo PDF. Không xem đây là thí nghiệm được chạy lại

Group DRO trên hai nhóm

Nhóm	Dữ liệu	Loss trung bình nhóm
A	$(1,4),(2,8)$	$J_A = 2.5(w-4)^2$
B	$(5,5),(6,6),(7,7),(8,8)$	$J_B = 43.5(w-1)^2$

Mô hình $f_w(x) = wx$, giữ nguyên lớp đường qua gốc

$$J_{\text{avg}} = \sum_g \frac{n_g}{n} J_g, \qquad J_{\text{DRO}} = \max_g J_g$$

Tại w = 1: loss A = 22,5, loss B = 0
Loss chung = 7,5, nhưng loss nhóm tệ nhất = 22,5

ERM và tối ưu nhóm tệ nhất

Mục tiêu	Nghiệm từ dữ liệu gốc	Đánh đổi
Trung bình theo mẫu	$w = 194/179 \approx 1.0838$	MSE chung thấp
Max theo nhóm	$w \approx 1.5801$	Loss hai nhóm ≈ 14,6395

$$g^* = \arg\max_g J_g(w), \qquad w \leftarrow w - \eta \nabla J_{g^*}(w)$$

Nếu nhiều nhóm cùng đạt max, dùng subgradient. Group DRO đổi mục tiêu, không tự tăng khả năng biểu diễn

Tự luyện – Một bước cập nhật nhóm A

Tại $w = 1$: gradient A $= 5(1 - 4) = -15$
Với $\eta = 0{,}01$, trọng số mới bằng **1,15**.

Thử trả lời trước khi bấm Tiếp

Tuyến tính theo trọng số

$$\phi(x) = [1, x, x^2]^\top, \qquad f_w(x) = w_0 + w_1 x + w_2 x^2$$

Theo biến nào?	Tuyến tính?
Trọng số w, feature cố định	Có
Feature $\phi(x)$, trọng số cố định	Có
Đầu vào x	Có thể phi tuyến

Đổi biểu diễn có thể tạo đường cong mà score vẫn là tích vô hướng

Hai ví dụ bậc hai

Tại $x = 3$, feature là $[1, 3, 9]$

Bộ trọng số	Phép tính	Dự đoán
$[1, 0, 0.5]$	$1 + 0 + 0.5 \times 9$	5,5
$[2, 1, -0.2]$	$2 + 3 - 0.2 \times 9$	3,2

Bộ thứ hai có hệ số bậc hai âm nên parabol mở xuống. Hình mở lên của slide gốc không khớp bộ trọng số đó

Từng đoạn và đặc trưng tuần hoàn

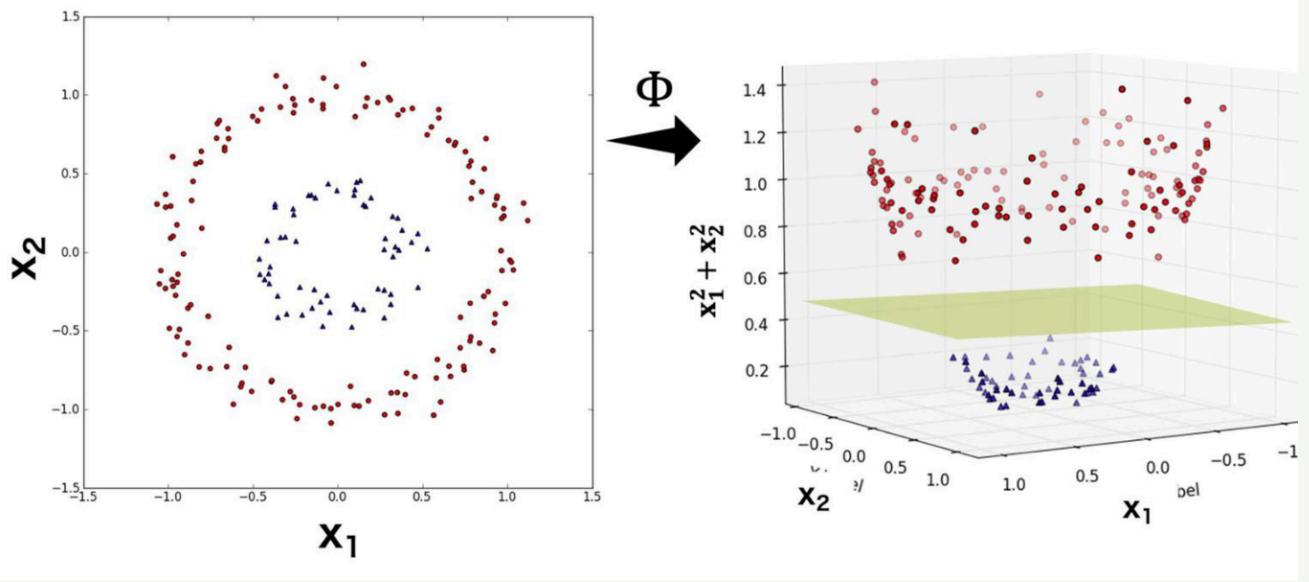
$$\phi_j(x) = \mathbf{1}[x \in I_j], \qquad f_w(x) = \sum_j w_j \phi_j(x)$$

Ví dụ từng đoạn: $\phi(2.3) = [0, 0, 1, 0, 0]$, $w = [1, 2, 4, 4, 3]$
Dự đoán bằng **4**

$$\phi(x) = [1, x, x^2, \cos(3x)]^\top$$

Ví dụ tuần hoàn tại x = 2 cho khoảng 3,5602. Cosine dùng radian. Chu kỳ T thường mã hóa bằng sin(2πx/T), cos(2πx/T)

Nâng chiều để tách cấu trúc vòng tròn



Hai tọa độ gốc và chiều bán kính bình phương, panel B022

Thêm $x_1^2 + x_2^2$ giúp mặt phẳng ở không gian feature tạo ranh giới tròn trong không gian gốc

Feature template và vector thưa

Khái niệm	Ví dụ
Template	“Ba ký tự cuối bằng ___”
Feature cụ thể	`endsWith com`, `endsWith org`
Sparse vector	Chỉ lưu thành phần khác không

Ví dụ: `{"endsWith com": 1}`

Các khóa không có trong mẫu được hiểu là **0**

> Template tổ chức feature. Dữ liệu học trọng số. Mạng nơ-ron còn học cả biểu diễn trung gian

Ví dụ email

Feature	Giá trị trong nguồn	Trọng số
length > 10	1	−1,2
fracOfAlpha	0,85	0,6
contains @	1	3
endsWith com	1	2,2
endsWith org	0	1,4

Score theo bảng = **4,51**, dự đoán nhãn dương

Với đúng chuỗi abc@gmail.com, tỷ lệ chữ cái theo ký tự là 10/13. Dùng tỷ lệ này cho score ≈ 4,4615

Tự luyện – Sparse có nghĩa là dữ liệu bị thiếu?

Theo quy ước ví dụ, khóa vắng là số không. Giá trị chưa biết là một tình huống khác, cần quy tắc xử lý riêng.

Thử trả lời trước khi bấm Tiếp

XOR và hai nút ẩn

An toàn khi $|x_1 - x_2| \geq 1$, với $x_1, x_2 \in \{0, 2\}$

Cặp vị trí	Nhãn
$(0,2), (2,0)$	+1
$(0,0), (2,2)$	−1

$$h_1 = \mathbf{1}[x_1 - x_2 \geq 1], \quad h_2 = \mathbf{1}[x_2 - x_1 \geq 1]$$

Đầu ra an toàn nếu h_1 hoặc h_2 bật. Một đường thẳng đơn lẻ không tách được XOR

Activation và đạo hàm

Hàm	Công thức	Đạo hàm
Sigmoid	$\sigma(z) = 1/(1+e^{-z})$	$\sigma(z)(1-\sigma(z))$
Tanh	$\tanh z$	$1 - \tanh^2 z$
ReLU	$\max(0, z)$	0 miền âm, 1 miền dương
Leaky ReLU	$\max(\alpha z, z)$	α miền âm, 1 miền dương

Sigmoid/tanh dễ bão hòa. ReLU có thể chặn gradient ở miền âm. Tại điểm gãy cần quy ước

Phi tuyến giữa các lớp

$$W_2(W_1x + b_1) + b_2 = (W_2W_1)x + (W_2b_1 + b_2)$$

- Nhiều lớp affine vẫn gộp thành một affine
- Activation phi tuyến làm lớp mô hình phong phú hơn
- Biểu diễn ẩn có thể học từ dữ liệu

Gợi ý lựa chọn: đầu ra hồi quy tuyến tính, nhị phân sigmoid, đa lớp loại trừ dùng softmax

Forward theo lớp và kích thước

$$a^{[0]} = x, \quad z^{[l]} = W^{[l]} a^{[l-1]} + b^{[l]}, \quad a^{[l]} = g^{[l]}(z^{[l]})$$

Đại lượng	Kích thước một mẫu
$W^{[l]}$	$n_l \times n_{l-1}$
$b^{[l]}, z^{[l]}, a^{[l]}$	$n_l \times 1$
Số tham số của lớp	$n_l(n_{l-1} + 1)$

Ví dụ forward: thiết lập

$$x = \begin{bmatrix} 1 \\ 2 \end{bmatrix}, \quad W^{[1]} = \begin{bmatrix} 1 & 1 \\ -1 & 1 \end{bmatrix}, \quad b^{[1]} = \begin{bmatrix} 0 \\ -2 \end{bmatrix}$$

$$W^{[2]} = [1, -1], \qquad b^{[2]} = -1$$

Lớp ẩn ReLU, đầu ra sigmoid. Nhãn thật y = 1

Ví dụ forward: kết quả

$$z^{[1]} = [3, -1]^\top, \qquad a^{[1]} = [3, 0]^\top$$

$$z^{[2]} = 1 \cdot 3 - 1 \cdot 0 - 1 = 2$$

$$\hat{y} = \sigma(2) \approx 0.8808, \qquad L = -\log \hat{y} \approx 0.1269$$

Dự đoán đúng lớp vẫn có BCE dương vì xác suất lớp đúng chưa bằng một

Tự luyện – Một mẫu bị ReLU chặn là dying ReLU?

Chưa đủ kết luận. Nút có thể nhận gradient ở mẫu khác. Cần xem nó có liên tục không hoạt động trên dữ liệu liên quan hay không.

Thử trả lời trước khi bấm Tiếp

Quy tắc chuỗi trên đồ thị

$$J = 3(a + bc), \qquad a = 5,\ b = 3,\ c = 2$$

Lượt xuôi	Giá trị
$u = bc$	6
$v = a + u$	11
$J = 3v$	33

Lượt ngược: ∂J/∂a = **3**, ∂J/∂b = **6**, ∂J/∂c = **9**

Một biến đi qua nhiều nhánh

$$J = x^2 + 3x, \qquad \frac{dJ}{dx} = 2x + 3$$

01 Tại x = 2, nhánh bình phương đóng góp 4

02 Nhánh nhân ba đóng góp 3

Cộng hai đóng góp: gradient bằng **7**

Nhân đạo hàm dọc đường phụ thuộc, cộng các đường ảnh hưởng khi gặp lại cùng một biến

Backprop loss bình phương

$$w = [3, 1]^\top, \quad \phi(x) = [1, 2]^\top, \quad y = 2$$

01 Dự đoán = 5, phần dư = 3, loss = 9

02 Gradient = 2 × 3 × (1,2) = (6,12)

03 Với η = 0,05: trọng số mới = (2,7, 0,4)

Dự đoán mới = **3,5**, loss mới = **2,25**

Mạng hai lớp: gradient đầu ra

$$p = 0.880797, \quad y = 1, \quad a^{[1]} = [3, 0]^\top$$

$$dZ^{[2]} = p - y \approx -0.119203$$

$$dW^{[2]} = dZ^{[2]} (a^{[1]})^\top \approx [-0.357609, 0]$$

$$db^{[2]} \approx -0.119203$$

Công thức p − y áp dụng cho sigmoid kết hợp BCE

Mạng hai lớp: gradient lớp ẩn

$$dA^{[1]} = (W^{[2]})^\top dZ^{[2]} \approx [-0.119203, +0.119203]^\top$$

$$dZ^{[1]} = dA^{[1]} \odot \mathrm{ReLU}'(z^{[1]}) \approx [-0.119203, 0]^\top$$

$$dW^{[1]} \approx \begin{bmatrix} -0.119203 & -0.238406 \\ 0 & 0 \end{bmatrix}$$

Nhánh thứ hai bị chặn vì tiền kích hoạt bằng −1

Cập nhật và forward lại

$$W^{[1]}_{\text{new}} \approx \begin{bmatrix} 1.011920 & 1.023841 \\ -1 & 1 \end{bmatrix}, \quad b^{[1]}_{\text{new}} \approx \begin{bmatrix} 0.011920 \\ -2 \end{bmatrix}$$

$$W^{[2]}_{\text{new}} \approx [1.035761, -1], \quad b^{[2]}_{\text{new}} \approx -0.988080$$

Sau một bước η = 0,1:
Xác suất ≈ **0,8996**, BCE ≈ **0,1058**

Tính mọi gradient từ cùng bộ tham số cũ rồi mới cập nhật đồng thời

Cấu hình loss khác, gradient khác

$$h = \sigma(V\phi(x)), \quad s = w^\top h, \quad L = (s-y)^2$$

$$\nabla_w L = 2(s-y)h$$

$$\nabla_V L = [2(s-y)w \odot h \odot (1-h)]\phi(x)^\top$$

Ví dụ này dùng sigmoid ẩn, đầu ra tuyến tính và loss bình phương. Giữ đúng cặp activation–loss

Mini-batch và một epoch

$$dW^{[l]} = \frac{1}{m} dZ^{[l]} (A^{[l-1]})^\top, \qquad db^{[l]} = \frac{1}{m} \sum_i dZ^{[l]}_{:,i}$$

$$dZ^{[l-1]} = (W^{[l]})^\top dZ^{[l]} \odot g'^{[l-1]}(Z^{[l-1]})$$

- Batch GD: toàn bộ train mỗi bước. SGD cơ bản: một mẫu
- Mini-batch: một nhóm mẫu mỗi bước
- Epoch: một lượt qua toàn bộ train, có thể gồm nhiều cập nhật

Khởi tạo và giới hạn tối ưu

Vấn đề	Điều cần nhớ
Khởi tạo giống nhau	Nút có thể giữ đối xứng, khó học khác nhau
Gradient nhỏ dần	Lớp xa loss khó nhận tín hiệu
Gradient bùng nổ	Cập nhật có thể không ổn định
Mục tiêu không lồi	Gradient đúng chưa bảo đảm nghiệm toàn cục

Backprop tính gradient. Optimizer dùng gradient. Generalization cần đánh giá riêng

Tự luyện – Bias trong ví dụ mạng phải dùng bộ nào?

Dùng $b^1 = (0, -2)$ để giữ $z^1 = (3, -1)$. Một số bảng nguồn ghi vector không nhưng không khớp forward. PDF đã nêu hiệu chỉnh.

Thử trả lời trước khi bấm Tiếp

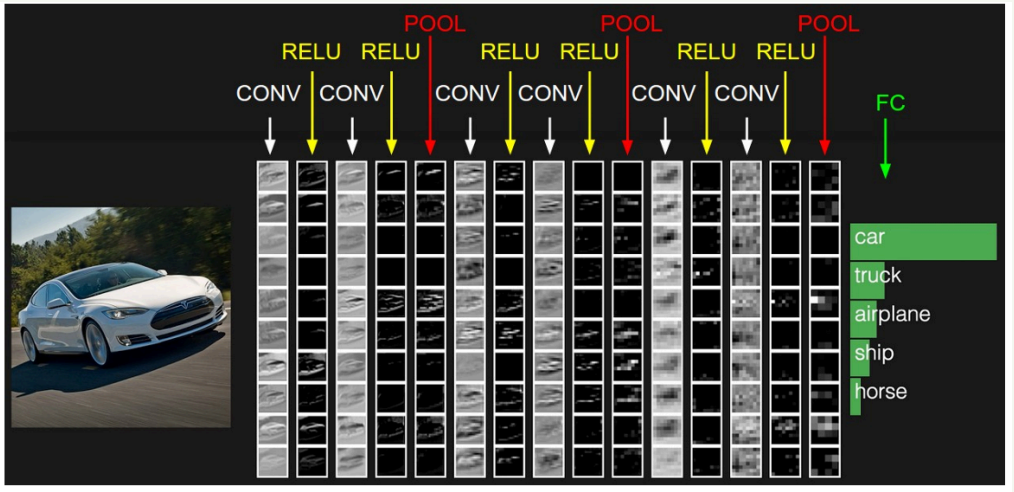
Lập trình khả vi và cấu trúc ảnh

Ảnh màu $540 \times 540 \times 3$ chứa **874.800 giá trị**

Lớp	Số tham số trong ví dụ
Dense tới 100 nút ẩn	87.480.000 trọng số, chưa bias
Conv 3×3, 3 kênh vào, 16 kênh ra	448, có bias

Đây là so sánh cơ chế đếm tham số. Hai lớp không có chức năng hoàn toàn tương đương

CNN: cục bộ và chia sẻ trọng số



Các khối conv, ReLU, pooling và đầu phân loại, panel C015

- **Cục bộ**: mỗi đầu ra nhìn một vùng nhỏ
- **Chia sẻ**: cùng bộ lọc trượt qua nhiều vị trí

Tích chập, ReLU và max pooling

$$X = \begin{bmatrix} 1 & 1 & 0 \\ 1 & 1 & 0 \\ 0 & 0 & 0 \end{bmatrix}, \quad K = \begin{bmatrix} 1 & 1 \\ 1 & 1 \end{bmatrix}$$

$$Z = \begin{bmatrix} 4 & 2 \\ 2 & 1 \end{bmatrix}, \quad \mathrm{ReLU}(Z) = Z, \quad \mathrm{MaxPool}_{2\times 2}(Z) = [4]$$

Stride 1, không padding, không bias. Mỗi ô đầu ra là tổng nhân từng phần tử trong cửa sổ

Stride, padding và kích thước

$$H_{\text{out}} = \left\lfloor \frac{H + 2p - k}{s} \right\rfloor + 1$$

Ký hiệu	Ý nghĩa
k	Kích thước kernel
s	Bước trượt
p	Padding ở mỗi phía

Thư viện thường gọi cross-correlation là convolution. Bộ lọc đối xứng trong ví dụ cho cùng kết quả khi lật

Tự luyện – ReLU có đổi ma trận (4,2;2,1) không?

Không vì mọi phần tử đều dương. Max pooling 2 × 2 sau đó giữ giá trị **4**.

Thử trả lời trước khi bấm Tiếp

Embedding và biểu diễn theo ngữ cảnh

$$E \in \mathbb{R}^{|V| \times d}, \qquad e_t = E[\text{token}_t]$$

- Token có thể là từ, mảnh từ hoặc ký tự
- Embedding tĩnh: cùng token nhận cùng vector ban đầu
- Hidden state: đã kết hợp thông tin ngữ cảnh

"Đường đông xe" và "cà phê nhiều đường" cần hai cách hiểu theo câu

Ví dụ hỏi đáp Tấm Cám

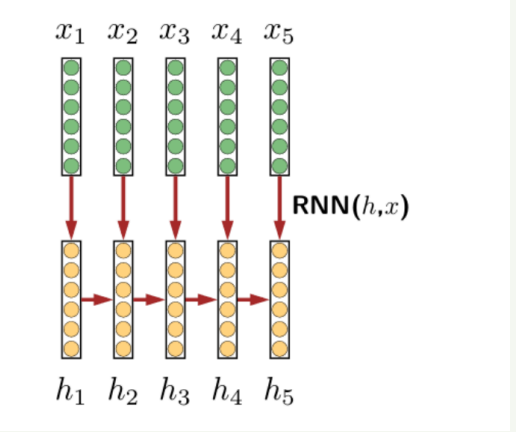
Đoạn văn cho biết cha Tấm **bệnh nặng rồi qua đời**
Sau đó Tấm phải sống cùng **dì ghẻ là mẹ Cám**

Câu hỏi gốc	Đáp án trong đoạn
Cha Tấm gặp chuyện gì trước khi qua đời?	Bệnh nặng
Sau khi cha mất, Tấm sống chung với ai?	Dì ghẻ

Cần nối nhân vật, sự kiện và câu hỏi. Tra vector từng từ riêng lẻ chưa đủ

RNN và trạng thái tuần tự

$$h_t = \tanh(W_h h_{t-1} + W_x e_t + b)$$



Cùng cell và cùng trọng số lặp lại qua thời gian, panel C026

Chiều dài chuỗi tăng số bước tính, không bắt buộc tăng số bộ trọng số

Phụ thuộc dài và gradient

$$\frac{\partial h_T}{\partial h_t} = \frac{\partial h_T}{\partial h_{T-1}} \cdots \frac{\partial h_{t+1}}{\partial h_t}$$

- Nhiều phép co liên tiếp có thể làm gradient biến mất
- Nhiều phép khuếch đại có thể làm gradient bùng nổ
- Các bước RNN phụ thuộc tuần tự vào bước trước

Ví dụ câu dài: chủ thể “con mèo” cách xa “đang ngủ”

LSTM: đường nhớ và các cổng

$$f_t = \sigma(W_f[h_{t-1}; e_t] + b_f), \quad i_t = \sigma(W_i[h_{t-1}; e_t] + b_i)$$

$$\tilde{c}_t = \tanh(W_c[h_{t-1}; e_t] + b_c), \quad c_t = f_t \odot c_{t-1} + i_t \odot \tilde{c}_t$$

$$o_t = \sigma(W_o[h_{t-1}; e_t] + b_o), \qquad h_t = o_t \odot \tanh(c_t)$$

Forget giữ/bỏ ký ức cũ, input nhận thông tin mới, output điều khiển phần xuất ra. LSTM không bảo đảm loại bỏ mọi khó khăn chuỗi dài

Collapse: chuỗi thành một đại diện

Cách chọn	Thông tin và hạn chế
First	RNN một chiều chưa thấy phần sau
Last	Đã tiếp nhận cả chuỗi, có thể yếu với phụ thuộc xa
Average	Dùng nhiều vị trí, có thể loãng tín hiệu quan trọng

$$c_{\text{avg}} = \frac{1}{T}\sum_{t=1}^{T} h_t$$

Loại padding khỏi trung bình. Chọn cách collapse theo mô hình và tác vụ

Tự luyện – Recurrent có cùng nghĩa với regression?

Không. Recurrent nói về hồi tiếp theo thời gian. Regression nói về tác vụ dự đoán đại lượng số.

Thử trả lời trước khi bấm Tiếp

Query, key và value

Thành phần	Vai trò
Query	Điều đang cần tìm
Key	Thông tin dùng so độ liên quan
Value	Nội dung được kết hợp

$$s_j = q^\top k_j, \qquad \alpha_j = \frac{e^{s_j}}{\sum_k e^{s_k}}, \qquad c = \sum_j \alpha_j v_j$$

Attention: ví dụ tính tay

$$q = [1, 0]^\top, \quad x_1 = [0, 1]^\top, \quad x_2 = [0, 0]^\top, \quad x_3 = [0, -1]^\top, \quad x_4 = [2, 0]^\top$$

01 Dot-product cho score (0,0,0,2)

02 Softmax ≈ (0,0963, 0,0963, 0,0963, 0,7112)

Tổng có trọng số ≈ **(1,4225, 0)**

Ví dụ gốc dùng cùng vector làm key và value, chưa chia tỷ lệ căn bậc hai

Self-attention và Q–K–V

$$Q = HW_Q, \qquad K = HW_K, \qquad V = HW_V$$

$$\text{Attention}(Q, K, V) = \text{softmax}\left(\frac{QK^\top}{\sqrt{d_k}} + M\right)V$$

- Token đặt theo hàng: ma trận score có kích thước $T \times T$
- Softmax theo từng hàng, đầu ra vẫn là chuỗi vector

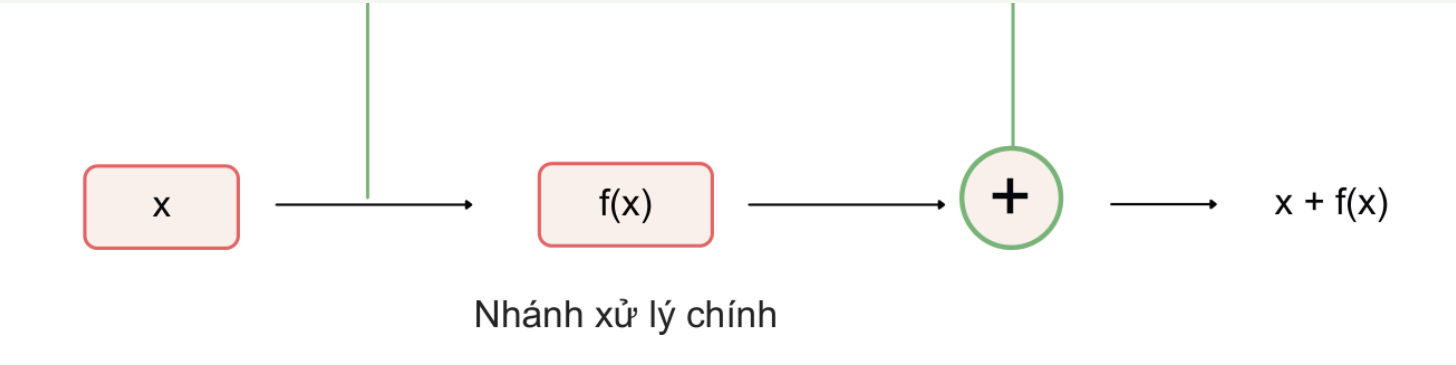
Mask, vị trí và multi-head

Cơ chế	Mục đích
Chia $\sqrt{d_k}$	Giữ score ở thang phù hợp
Padding mask	Bỏ vị trí đệm
Causal mask	Không nhìn token tương lai
Thông tin vị trí	Cung cấp thứ tự token
Multi-head	Nhiều bộ chiếu học các quan hệ khác nhau

Cross-attention lấy query và key/value từ các chuỗi khác nhau. Attention đầy đủ có ma trận score tăng theo T^2

Residual connection

$$y = x + f(x), \qquad \frac{\partial y}{\partial x} = I + \frac{\partial f(x)}{\partial x}$$



Đường tắt và nhánh xử lý, panel C039

Tạo đường truyền thông tin và gradient trực tiếp. Hai nhánh phải có kích thước phù hợp. Nó hỗ trợ, không bảo đảm tuyệt đối ổn định gradient

Layer normalization

$$\mu = \frac{1}{d}\sum_j x_j, \quad \sigma^2 = \frac{1}{d}\sum_j (x_j - \mu)^2$$

$$\mathrm{LN}(x)_j = \gamma_j \frac{x_j - \mu}{\sqrt{\sigma^2 + \epsilon}} + \beta_j$$

Ví dụ: $[100, 200, 300]$ thành khoảng $[-1.2247, 0, 1.2247]$

Giả sử scale = 1, shift = 0, epsilon rất nhỏ

Chuẩn hóa các chiều trong một token. Khác chuẩn hóa dữ liệu train và batch normalization

Một khối Transformer

$$U = \mathrm{LN}(H + \mathrm{Attention}(H))$$

$$H' = \mathrm{LN}(U + \mathrm{FFN}(U))$$

Khối	Vai trò
Attention	Kết hợp giữa các vị trí
FFN	Biến đổi từng vị trí, dùng chung trọng số
Residual + LayerNorm	Hỗ trợ luồng thông tin và thang giá trị

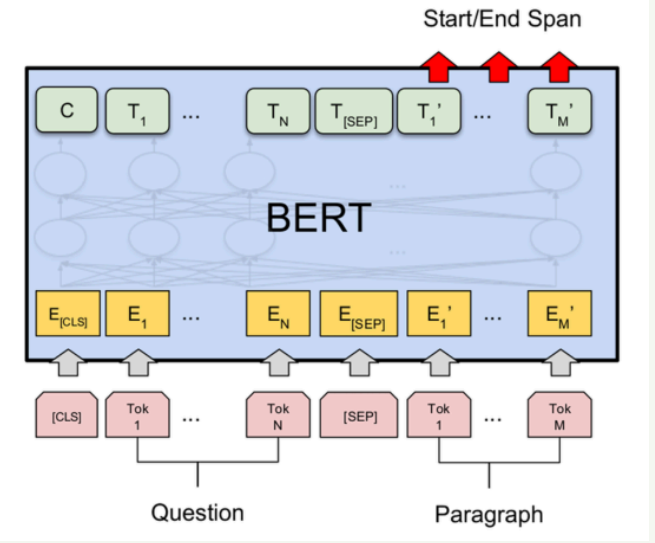
Đây là cách sắp post-norm. Pre-norm đặt chuẩn hóa trước nhánh con

Tự luyện – Self-attention tự thu cả câu thành một vector?

Không. Thường có một vector ngữ cảnh tại mỗi vị trí. Tác vụ phân loại cả câu cần cách lấy đại diện phù hợp.

Thử trả lời trước khi bấm Tiếp

BERT và hỏi đáp theo đoạn



Câu hỏi và đoạn văn đi vào BERT, hai đầu Start/End chọn span, panel C044

Ví dụ chọn cụm “bệnh nặng”. Con số 24 khối trong nguồn là một cấu hình, không áp dụng cho mọi BERT

Chọn span và sinh token

Cách dùng	Đầu ra trực tiếp
BERT extractive QA	Vị trí đầu/cuối trong đoạn
LM tự hồi quy	Phân phối token kế tiếp

$$p_i^{\text{start}} = \text{softmax}_i(w_s^\top h_i), \quad p_i^{\text{end}} = \text{softmax}_i(w_e^\top h_i)$$

Span phải thuộc phần văn bản hợp lệ, vị trí cuối không trước vị trí đầu

Mô hình ngôn ngữ tự hồi quy

$$s_v = h^\top u_v + b_v, \qquad p(x_t = v \mid x_{<t}) = \mathrm{softmax}(s)_v$$

$$p(x_{1:T}) = \prod_{t=1}^{T} p(x_t \mid x_{<t})$$

$$\mathcal{L} = -\sum_{t} \log p(x_t \mid x_{<t})$$

Sinh token, ghép vào tiền tố, rồi lặp tới token kết thúc hoặc giới hạn độ dài

Huấn luyện, giải mã và seq2seq

- **Teacher forcing**: dùng token thật trước đó trong lúc train
- **Greedy**: chọn token xác suất lớn nhất mỗi bước
- **Sampling**: lấy mẫu từ phân phối, có thể tạo nhiều đầu ra
- **Seq2seq**: đầu ra còn phụ thuộc chuỗi nguồn

$$p(y_{1:T} \mid x) = \prod_{t} p(y_t \mid y_{<t}, x)$$

Ví dụ gốc: “Chiếc xe màu đỏ” thành “The red car”. Greedy tối ưu cục bộ, chưa bảo đảm câu tốt nhất

Tự luyện – Khi sinh câu, mô hình có biết token thật phía sau?

Không trong thiết lập tự hồi quy. Causal mask ngăn nhìn tương lai khi học, và lúc sinh tiền tố chứa các token đã chọn.

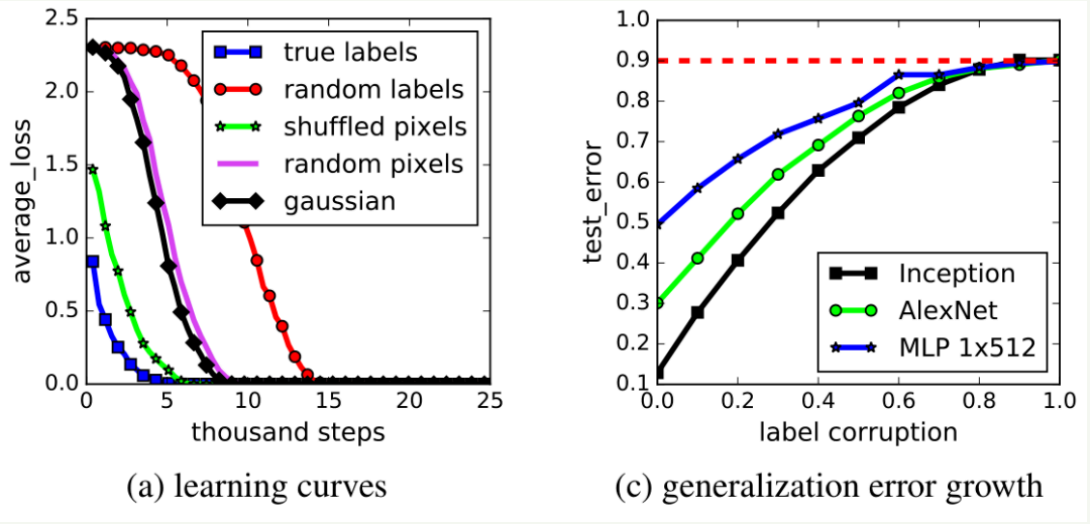
Thử trả lời trước khi bấm Tiếp

Thiếu khớp và quá khớp

Hiện tượng	Điều cần kiểm tra
Underfitting	Train và validation đều kém
Overfitting	Train cải thiện, validation không tương ứng
Khác phân phối	Dữ liệu triển khai khác dữ liệu học/đánh giá

Train loss thấp chỉ xác nhận độ khớp dữ liệu đã học. Mục tiêu là dự đoán trên phân phối cần sử dụng

Nhãn ngẫu nhiên và khả năng ghi nhớ



Trái: loss theo bước học. Phải: lỗi test theo tỷ lệ nhãn hỏng, panel C061

Mạng có thể khớp train khi nhãn bị xáo. Điều đó chưa chứng minh tổng quát hóa tốt. Số liệu được thuật lại theo nguồn

Phân rã sai số

$$g = \arg\min_{f \in \mathcal{F}} \mathrm{Err}(f)$$

$$\mathrm{Err}(\hat{f}) - \mathrm{Err}(f^*) = E_{\mathrm{est}} + E_{\mathrm{app}}$$

$$E_{\mathrm{est}} = \mathrm{Err}(\hat{f}) - \mathrm{Err}(g), \quad E_{\mathrm{app}} = \mathrm{Err}(g) - \mathrm{Err}(f^*)$$

Lớp phong phú có thể giảm sai số xấp xỉ. Hạng mô hình thực học còn có thể chứa ảnh hưởng sai số tối ưu

L2 và mức độ khớp

$$w \leftarrow (1 - \eta\lambda)w - \eta\nabla J_{\text{train}}(w)$$

Điều chỉnh	Tác dụng có thể có
Ít feature / ít khả năng biểu diễn	Giảm quá khớp, có thể tăng thiếu khớp
L2 lớn hơn	Hạn chế trọng số lớn
Ít bước học	Hạn chế tiếp tục khớp nhiễu

Chọn mức điều chuẩn bằng validation. Với optimizer thích nghi, không tự đồng nhất mọi L2 với mọi weight decay

Early stopping

Epoch	Train loss	Validation loss
10	0,30	0,36
20	0,20	**0,29**
30	0,14	0,32
40	0,10	0,37

Giữ checkpoint epoch **20**, dù epoch 40 khớp train hơn

Lưu mốc tốt nhất, dừng sau patience không cải thiện, rồi khôi phục mốc tốt nhất. Bảng là ví dụ minh họa

Tự luyện – Mạng lớn có luôn quá khớp?

Không. Cần xem dữ liệu, cách học, điều chuẩn và đánh giá. Thí nghiệm nhãn ngẫu nhiên chỉ cho thấy train loss thấp chưa đủ chứng minh generalization.

Thử trả lời trước khi bấm Tiếp

Train, validation và test

Tập	Vai trò
Train	Học trọng số, fit các phép biến đổi
Validation	Chọn cấu hình và checkpoint
Test	Đánh giá cuối sau khi chốt quy trình

Dữ liệu cùng người hoặc theo thời gian cần cách chia phản ánh tình huống triển khai

K-fold cross-validation

- Chia dữ liệu phát triển thành K fold
- Mỗi lượt: một fold validation, $K-1$ fold train
- Huấn luyện lại và fit tiền xử lý trong train của lượt đó

$$\bar{S} = \frac{1}{K}\sum_{k=1}^{K} S_k$$

Test giữ riêng. Tổng hợp cả mức trung bình và biến thiên khi phù hợp

Chu trình phát triển và rò rỉ dữ liệu

Baseline
Train và validation

→

Phân tích lỗi
Thử thay đổi có mục đích

→

Chốt mô hình
Train cuối, đánh giá test

- Không fit chuẩn hóa cả bộ trước khi chia fold
- Không liên tục chọn cấu hình theo cùng test
- Ghi cách chia, tiền xử lý, cấu hình, seed và metric

Confusion matrix và metric theo lớp

Đại lượng	Mẫu số
Recall lớp k	Mọi mẫu thật của lớp k
Precision lớp k	Mọi mẫu được dự đoán là lớp k
Accuracy	Mọi mẫu test

Ví dụ Digits trong PDF: accuracy **96,89%**
Chữ số 3 đúng **79/91**, nhầm 12 mẫu sang 5, 7 hoặc 8

Recall lớp 3 = 79/91 ≈ **86,81%**, thấp hơn con số tổng thể

Tự luyện – Tính precision lớp 3 bằng tổng hàng 3?

Không. Hàng là nhãn thật, cột là nhãn dự đoán trong ma trận này. Precision cần tổng cột 3, recall cần tổng hàng 3.

Thử trả lời trước khi bấm Tiếp

Phân cụm không giám sát

Phân loại	K-means
Có nhãn y_i khi học	Chỉ có vector đặc trưng
Học quy tắc dự đoán nhãn	Tìm phép gán và tâm cụm
Nhãn có ý nghĩa đã định	Chỉ số cụm có thể hoán vị

$$J(z, \mu) = \sum_i \|\phi(x_i) - \mu_{z_i}\|^2$$

Một cụm không tự động là một lớp có ý nghĩa ngữ nghĩa

Hai bước của K-means

$$z_i \leftarrow \arg\min_k \|\phi(x_i) - \mu_k\|^2$$

$$\mu_k \leftarrow \frac{1}{|C_k|} \sum_{i \in C_k} \phi(x_i)$$

- Giữ tâm để gán về cụm gần nhất
- Giữ phép gán để cập nhật tâm bằng trung bình

Cụm rỗng cần quy tắc riêng. Dừng khi gán/tâm ổn định hoặc đạt tiêu chí đã chọn

Ví dụ bốn điểm

Dữ liệu: **0, 2, 10, 12**, tâm ban đầu **0 và 10**

01 Gán cụm: {0,2} và {10,12}, loss = 8

02 Cập nhật tâm: 1 và 11

Loss mới = **4**. Gán lại không đổi

Tâm không cần trùng một điểm dữ liệu

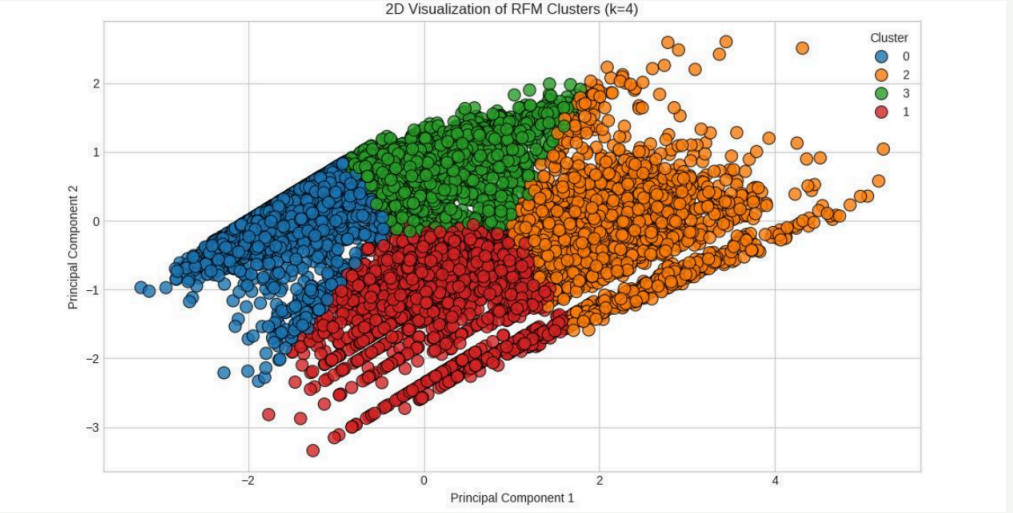
Loss không tăng và giới hạn nghiệm

$$J(z^{t+1}, \mu^{t+1}) \leq J(z^{t+1}, \mu^{t}) \leq J(z^{t}, \mu^{t})$$

- Hai bước đều giải tốt nhất bài toán con khi giữ phần còn lại cố định
- Nghiệm chung có thể phụ thuộc khởi tạo
- Chạy nhiều lần, so loss với cùng K
- K-means++ hỗ trợ khởi tạo, chưa bảo đảm nghiệm toàn cục

Thêm cụm thường giảm loss. Chọn K chỉ theo loss nhỏ nhất có thể dẫn tới mỗi điểm một cụm

RFM và hình chiếu PCA



PCA hai chiều của các cụm hành vi, panel C083

R: thời gian từ lần mua gần nhất. **F**: tần suất. **M**: chi tiêu

Chuẩn hóa thang đo phù hợp. Trục PCA khác đặc trưng RFM gốc. Tên cụm cần dựa vào thống kê và mục đích sử dụng

Tự luyện – Màu số 2 luôn là khách hàng mua nhiều?

Không. Chỉ số cụm có thể hoán vị giữa lần chạy. Phải xem tâm, phân bố RFM và mục tiêu trước khi đặt tên.

Thử trả lời trước khi bấm Tiếp

Các điểm dễ nhầm

Cặp	Phân biệt ngắn
Model / optimizer	Hàm dự đoán / cách tìm tham số
Score / xác suất	Điểm thô / phân phối sau biến đổi
Backprop / update	Tính gradient / thay tham số
Feature / template	Phép đo cụ thể / họ quy tắc
Attention / collapse	Kết hợp vị trí / thu thành đại diện
Loss giảm / test tốt	Tối ưu dữ liệu học / đánh giá dữ liệu mới

Các hiệu chỉnh cần giữ đúng

Ví dụ trong nguồn	Kết quả nhất quán dùng trong bộ slide
Group DRO	ERM ≈ 1,0838, không làm tròn thành 1,09
Parabol $2 + x - 0.2x^2$	Mở xuống, dù hình nguồn mở lên
Email	0,85 là giá trị minh họa, phép đếm ký tự cho 10/13
Forward/backprop hai lớp	Bias lớp ẩn (0, −2)
Multiclass hinge	Score sai − score đúng + biên
LayerNorm	Tên đúng, có scale/shift học được

Tự kiểm tra theo 14 chương

Chương 1. Ngôn ngữ chung của học máy

1 / 5

Câu 1.1 – Ghi nhớ

Ba quyết định thiết kế là gì?

Câu trước | Xem đáp án | Câu tiếp

Tự trả lời, sau đó mở đáp án để đối chiếu.
Các bài liên chương có lời giải dài, có thể cuộn trong khung đáp án.

Bảng tra công thức

Chủ đề	Công thức cốt lõi
Gradient descent	$\theta \leftarrow \theta - \eta \nabla J$
L2	$J + \frac{\lambda}{2}\lvert w\rvert^2$
Hinge	$\max(0, 1 - ys)$
BCE + sigmoid	$dZ = p - y$
Softmax + CE	$\partial L / \partial s_j = p_j - \mathbf{1}[j = y]$
K-means	$\sum_i \lvert\phi(x_i) - \mu_{z_i}\rvert^2$

Kiểm tra quy ước loss, nhãn, số mẫu và kích thước trước khi thay công thức

Tài liệu và lời giải đầy đủ

14 chương kiến thức trong bộ slide
Ví dụ số, công thức và các điều kiện quan trọng

72 câu ôn tập trong ngân hàng tương tác
Đáp án, bài liên chương và checklist tự đánh giá

Mở giáo trình ML đầy đủ Mở bản slide PDF

Mở PDF theo số trang để xem lại hình nguồn, lời giải dài và bảng đối chiếu 235 trang bài giảng